

Automatic Classification of Soot Propensity in Flames Using Image Processing and Machine Learning

Alonso Rodríguez, Alexis Diomedi, Jorge Portilla, Hugo Garcés, and Gonzalo Carvajal

Abstract—This paper describes and evaluates different approaches for determining the soot propensity of an axisymmetric laminar diffusion flame with respect to its smoke point. Using a training dataset of images of flames captured in laboratory conditions and labeled according to Line-Of-Sight Attenuation (LOSA) measurements, we trained different classifiers for determining the soot propensity of flames using images in a testing dataset. We evaluate a traditional classifier based on Support Vector Machine (SVM), combined with dimensionality reduction techniques and compare the results with different architectures of Convolutional Neural Networks (CNNs). Experimental results in terms of classification performance and inference time set the proposed classifiers as a promising solution for non-invasive and low-cost instrumentation for characterizing the status of combustion flames in industrial settings.

Keywords—Combustion, Smoke Point, Soot Propensity, Machine Learning, Image Processing, Support Vector Machine, Convolutional Neural Networks

I. INTRODUCCIÓN

LOS procesos de combustión industrial son una de las principales fuentes de emisión de partículas contaminantes a la atmósfera. La acumulación de estas partículas tiene efectos negativos en la salud humana y contribuye al calentamiento global, por lo que existe un creciente interés en el desarrollo de sistemas de combustión eficientes que permitan maximizar la generación de energía, al mismo tiempo de minimizar la emisión de partículas contaminantes al ambiente.

Una forma directa de reducir la emisión de material particulado en procesos de combustión es utilizar combustibles que tengan baja propensión a generar hollín. Una forma de caracterizar la calidad de un combustible en este contexto corresponde a su *smoke point*, el cual se obtiene observando el punto crítico de ingesta de combustible a la llama en que comienza la liberación de material particulado al ambiente debido a su combustión incompleta, este punto es determinado mediante la utilización de equipamiento estándar en condiciones de laboratorio [1]. El *smoke point* entrega un indicador de la tendencia de un combustible a liberar partículas de hollín al ambiente.

This work was funded through grants FONDECYT 11160375, CONICYT-Basal Project FB0008, and FONDEF IDEA ID18I10236.

A. Rodríguez, A. Diomedi, J. Portilla, and G. Carvajal are with the Department of Electronics, Universidad Técnica Federico Santa María, Valparaíso, Chile (e-mail: alonso.rodriguez.13@sansano.usm.cl, alexis.diomedi.12@sansano.usm.cl, jorge.portilla@sansano.usm.cl, gonzalo.carvajal@usm.cl)

H. Garcés is with the Department of Informatics, Universidad Católica de la Santísima Concepción, Concepción, Chile (e-mail: hugogarcés@ucsc.cl)

El estándar ASTM D1322 [2] define una metodología genérica para determinar el *smoke point* en base a una altura crítica llamada *Smoke Point Height* (SPH), en que la llama presenta variaciones morfológicas en su punta y comienza a liberar hollín, la cual puede ser determinada mediante métodos manuales o automatizados. La caracterización manual implica tomar repetidas observaciones por un operador humano, lo cual inherentemente conlleva a incertidumbre en las mediciones y baja reproducibilidad. Debido a esto, hay una gran actividad de investigación en torno al desarrollo de técnicas e instrumentación para facilitar o automatizar la detección del *smoke point*. Dentro de estos, los métodos basados en procesamiento de imágenes resultan particularmente atractivos debido a que son no intrusivos y requieren de equipamiento relativamente simple y de bajo costo en relación a otras técnicas usadas en entornos de laboratorio.

Los procedimientos estándar de caracterización del *smoke point* consideran entornos de laboratorio altamente controlados y sin perturbaciones externas. Una de las principales técnicas empleadas son métodos de Line-Of-Sight Attenuation (LOSA), en los cuales se proyecta un láser sobre un foto-receptor atravesando la llama, de forma de determinar la cantidad de luz recibida por el receptor, la cual se espera reduzca cuando la llama comience a liberar hollín [3]. De forma similar, se emplean otras técnicas basadas en cambios morfológicos de la punta de la llama o condiciones de brillo de esta [4]. La aplicación de estas técnicas suele realizarse mediante procesamiento fuera de línea utilizando datos pre-grabados, lo cual permite caracterizar la calidad del combustible, pero no el estado del proceso de combustión. Además, el estándar ASTM D1322 y los métodos tradicionales se enfocan en la caracterización precisa del *smoke point*, para lo cual se emplea un entorno controlado y una metodología para aumentar el flujo de combustible a intervalos fijos, enfocándose únicamente en encontrar el punto crítico de liberación de hollín, sin prestar atención a los tiempos de cómputo asociado, ni a los puntos de operación fuera del *smoke point*, los cuales podrían ser empleados para mantener la llama en un estado controlado aumentando la calidad de la combustión.

En este trabajo se proponen, evalúan y comparan nuevos métodos para la determinación automática del *smoke point* utilizando procesamiento de imágenes y técnicas de aprendizaje de máquinas con el objetivo de explorar nuevos enfoques para expandir las aplicaciones de la caracterización del *smoke point*. En estos aspectos, el trabajo presenta las siguientes contribuciones:

- Se utilizan datos etiquetados considerando llamas de distintas configuraciones y en distintos puntos de operación con respecto a su *smoke point*, lo cual permite caracterizar no solo si una llama se encuentra en su punto crítico, sino que también si esta se encuentra sobre o bajo este.
- El uso de técnicas de aprendizaje de máquinas (*machine learning*), en particular el uso de redes neuronales convolucionales, permite abstraer información acerca de las características y relaciones complejas de la llama en cualquier punto de operación, mas allá de las características empleadas en métodos de procesamiento tradicionales. Estas técnicas tienen el potencial de medir el estado de la llama respecto de su *smoke point* bajo condiciones de operación no ideales, lo cual puede potenciar su uso en entornos no controlados fuera del laboratorio.
- El uso de estas técnicas permite la utilización de plataformas de computación embebidas que habiliten el uso de procesamiento en línea para la estimación instantánea del punto de operación de la llama. Esto abre paso al desarrollo de instrumentación especializada y de bajo costo que pueda ser empleada en entornos industriales para el monitoreo en línea de las condiciones del proceso de combustión, que formen parte de plataformas de control que permitan mantener la llama en su punto óptimo para el control de emisiones al ambiente.

El resto de este trabajo se organiza de la siguiente forma. La sección II presenta una revisión de otros procesamientos existentes que utilizan técnicas de aprendizaje de máquinas y procesamiento de imágenes. La sección III describe los algoritmos empleados en este trabajo. La sección IV describe la metodología para obtener los resultados experimentales descritos en la sección V. Finalmente, la sección VI concluye el documento y discute posibles trabajos futuros que pueden derivar de este análisis.

II. TRABAJOS RELACIONADOS

Si bien existen trabajos previos que tratan el problema de detectar el *smoke point* en llamas de forma automática, la utilización de métodos de aprendizaje de máquinas es relativamente reciente. En [5] se utilizan clasificadores basados en *Support Vector Machine* (SVM), entrenados con un conjunto de imágenes RGB de llamas en un ambiente controlado de laboratorio para poder clasificarlas en tres categorías según estas se encuentren sobre, bajo o en el *smoke point*. Para aumentar la robustez del algoritmo, los autores utilizan en el proceso de entrenamiento del clasificador imágenes de llamas alimentadas con aire enriquecido con distintos porcentajes de oxígeno, lo cual genera variaciones considerables en la forma, tamaño e intensidad lumínica de las llamas en sus distintas categorías respecto a su *smoke point*. En el presente trabajo se utiliza el mismo conjunto de datos con algunas modificaciones para adaptar las imágenes a la entrada de los modelos de clasificación propuestos y para mejorar la generalización de los mismos. Por otro lado, en [4] se utiliza un método basado en técnicas clásicas de procesamiento de imágenes. En este trabajo se usa una cámara web simple para obtener imágenes de la llama de una lámpara de prueba construida

según el estándar ASTM D1322, empleado comúnmente en la determinación del SPH de una llama, junto con un sistema para manipular de forma automática la ingesta de combustible a esta. Utilizando una plataforma específicamente diseñada para el experimento, se obtienen capturas de la llama segmentando según brillo y forma la punta del cuerpo de la llama, luego se propone un método para estimar el estado de esta con respecto a su *smoke point* en base a la relación de volúmenes de estos dos segmentos. A la fecha no se conocen trabajos que traten de forma específica la utilización de redes neuronales convolucionales (CNNs) para detectar el estado de una llama respecto de su *smoke point*.

III. ALGORITMOS PROPUESTOS

Como parte del proceso de validación de los resultados presentados en [5], se implementa un clasificador basado en *Support Vector Machine* (SVM), considerando una etapa previa de reducción de dimensionalidad mediante *Principal Component Analysis* (PCA). Adicionalmente se realizan pruebas reemplazando el algoritmo de PCA para reducción de dimensionalidad por *Linear Discriminant Analysis* (LDA), comparando el desempeño de ambos métodos. Se evalúan de igual forma clasificadores basados en CNN, para esto se utilizan dos arquitecturas pre-entrenadas y una arquitectura de aplicación específica diseñada de forma manual y sin pre-entrenamiento. Se evalúa entonces el desempeño en la predicción de cada uno de los algoritmos propuestos, comparando también su tiempo de inferencia promedio a fin de determinar la pertinencia de su uso en aplicaciones de tiempo real.

A. Reducción de dimensionalidad

Como parte del proceso de construcción del clasificador por SVM se considera una etapa previa de pre-procesamiento basado en la reducción de dimensionalidad del conjunto de imágenes de llama. Una imagen puede representarse como un vector de valores de píxel (por ejemplo, una imagen RGB de 224×224 puede ser representada con un vector que contenga 150.528 valores). La representación vectorizada de una imagen permite aplicar transformaciones lineales para pasar de un espacio de píxeles a un espacio de características de dimensión reducida. Existen distintas técnicas para determinar transformaciones que cumplan con distintos objetivos al proyectar las imágenes al espacio de características, destacándose entre las más usadas PCA y LDA.

1) *PCA*: La reducción de dimensionalidad mediante PCA apunta a recodificar la información de un conjunto de vectores de entrenamiento en base a las direcciones que maximizan la varianza dispersa en todo el conjunto de datos. Esta técnica permite generar representaciones compactas a partir de conjuntos con redundancia y alta dimensionalidad, por lo que presenta utilidad en la reducción de los requerimientos de almacenamiento y cómputo, además de facilitar el entrenamiento de los clasificadores.

Este algoritmo proyecta las imágenes de llama en dimensiones reducidas manteniendo las características principales. La matriz de transformación W se calcula obteniendo los vectores propios de mayor varianza según (1). La matriz de

covarianza descrita en (2) se forma por medio del set de datos de entrenamiento $\mathbf{X}$, el cual esta conformado por todas las imágenes de llama, donde cada imagen en el conjunto es vectorizada en sus componentes de colores RGB.

$$\mathbf{W} = \text{eigen}\{\text{cov}(\mathbf{X})\} \quad (1)$$

$$\text{cov}(\mathbf{X}) = \mathbb{E}[\mathbf{X} \times \mathbf{X}^T] \quad (2)$$

2) *LDA*: LDA también utiliza proyecciones lineales pero, a diferencia de PCA que considera un conjunto global de imágenes, utiliza la información asociada a la etiqueta de cada muestra del conjunto de entrenamiento para encontrar una proyección lineal que maximice la diferencia entre clases en el espacio reducido, facilitando así la posterior tarea de clasificación. Formalmente, la matriz de dispersión entre clases $\mathbf{S}_b$ y la matriz de dispersión dentro de las clases $\mathbf{S}_w$ siguen la expresión descrita por las expresiones

$$\mathbf{S}_b = \sum_{i=1}^c N_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T \quad (3)$$

$$\mathbf{S}_w = \sum_{i=1}^c \sum_{\mathbf{x}_k \in \mathbf{X}_i} (\mathbf{x}_k - \boldsymbol{\mu}_i)(\mathbf{x}_k - \boldsymbol{\mu}_i)^T \quad (4)$$

En (3), $\boldsymbol{\mu}$, $\boldsymbol{\mu}_i$, N_i y c corresponden a la imagen media de todas las muestras de entrenamiento, imagen media de las muestras sujetas a una clase, el número de imágenes en la clase y el número de clases, respectivamente. En (4), $\mathbf{x}_i$ es un subconjunto de N_i imágenes sujetas a una clase y $\mathbf{x}_k$ corresponde a las imágenes dentro de una clase específica. La transformación óptima $\mathbf{W}$ se encuentra resolviendo el problema de valores propios generalizado

$$(\mathbf{S}_b \mathbf{S}_w^{-1}) \mathbf{w}_i = \lambda_i \mathbf{w}_i \quad (5)$$

cuya solución corresponde a los vectores propios que maximizan la varianza entre las distintas clases y que al mismo tiempo minimizan la varianza dentro de los elementos de una misma clase. Donde $\mathbf{w}_i$ es un conjunto de vectores propios de $\mathbf{S}_b$ y $\mathbf{S}_w$ correspondiente a los valores propios λ_i .

Como resultado, los elementos asociados a una misma clase proyectados al espacio reducido utilizando esta transformación tienden a agruparse entre sí separados del resto de las clases, formándose así conjuntos con alta diferenciación que facilitan la tarea de clasificación.

Como se discute en [6], en la práctica generalmente se plantean dos restricciones para el cálculo de la transformación óptima en la ecuación (5). $\mathbf{S}_b$ es una matriz que corresponde a la suma de por lo menos $c - 1$ matrices linealmente independientes, su rango máximo será $c - 1$, lo que además es una cota para el número de valores propios distintos de 0 y por lo tanto el número de características que se pueden obtener. Por otra parte, la matriz $\mathbf{S}_w$ tiene un rango de a lo más $N - c$, donde N es el número de imágenes de muestra.

B. Support Vector Machine

La generación de un clasificador SVM se basa en encontrar un hiperplano que separe las distintas clases existentes en los vectores de los datos de entrenamiento. Para esto se utiliza una

función kernel $\Omega(\mathbf{x}_i, \mathbf{X}_t)$ que traslada los vectores originales de entrada $\mathbf{X}_t$ a un espacio de alta dimensión para asegurar su separabilidad lineal a través de estos hiperplanos. Encontrar el hiperplano óptimo que separa dos clases es equivalente a resolver el problema de optimización descrito en la siguiente expresión:

$$\mathbf{y} = \sum_{i=1}^N \mathbf{w}_i \Omega(\mathbf{x}_i, \mathbf{X}_t) + \mathbf{b} \quad (6)$$

en que $\mathbf{y}$ es el resultado de la clasificación, $\mathbf{w}_i$ es el peso i -ésimo adaptado al modelo, $\mathbf{x}_i$ es el vector de soporte i -ésimo y $\mathbf{b}$ es el bias o sesgo del hiperplano con respecto al origen. En general, el objetivo es calcular los valores de la matriz de pesos $\mathbf{w}^*$ que cumplan con (7).

$$(\mathbf{w}^*, \mathbf{b}) = \underset{\mathbf{w}, \mathbf{b}, \boldsymbol{\xi}}{\text{argmin}} \frac{1}{2} \|\mathbf{w}^*\|^2 + \mathbf{C} \sum_{i=1}^S \xi_i \quad (7)$$

$$\mathbf{y}_i(\mathbf{w}^* \mathbf{x}_i + \mathbf{b}) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (8)$$

donde S hace referencia al número de kernels y $\mathbf{C}$ es un parámetro de penalización elegido durante el entrenamiento. La ecuación (7) está sujeta a la restricción (8), debido a que dentro del problema de optimización se introducen variables de holgura cuando los datos no son reparables para permitir violar las restricciones [7]. ξ_i es el vector de holgura que hace referencia al tamaño de dichas violaciones.

C. Redes neuronales convolucionales

La redes neuronales artificiales han visto en años recientes un aumento considerable en su aplicación a numerosos problemas de procesamiento de datos [8]. En particular, para procesamiento de imágenes, las arquitecturas dominantes son aquellas basadas en la aplicación de múltiples bancos de filtros convolucionales en conjunto con operaciones de sub-muestreo espacial, conocidas como redes neuronales convolucionales (CNN). En este trabajo se evalúan distintas arquitecturas de CNN para la clasificación del estado de combustión de llamas con respecto a su *smoke point*.

1) *Modelos basados en redes pre-entrenadas*: Existen variadas arquitecturas de CNN que han sido pre-entrenadas con el objetivo de clasificar una gran variedad de objetos. Estas redes son comúnmente entrenadas empleando conjuntos de datos públicos con cientos o miles de etiquetas distintas [9], donde la gran variedad permite que las capas de las primeras etapas de estos modelos aprendan a extraer características suficientemente generalizables como para ser utilizadas en tareas distintas a su propósito original. Esta técnica es conocida como *transfer learning*, y es utilizada tanto para cuando no se tienen suficientes datos como para un entrenamiento robusto como para cuando se busca entrenar una red que realice tareas similares.

En este trabajo se emplean MobileNet [10] y VGG16 [11], cuyos pesos pre-entrenados fueron congelados para el entrenamiento, agregando unas pocas capas finales descritas en la Tabla I para adaptar sus resultados a la aplicación luego de un entrenamiento en base al conjunto de datos descrito en la sección IV. A los pesos de las capas finales se les

Tabla I: Arquitectura de las capas finales de la red pre-entrenada.

Tipo	Maps	Kernel/stride	Tamaño	Activación
MobileNet	1280	-	7x7	ReLU
AvgPool	-	Global	1280	-
Dense	-	-	32	Sigmoide
Dense	-	-	3	Softmax

VGGNet	512	-	7x7	-
Flatten	-	-	25088	-
BatchNorm	-	-	25088	-
Dense	-	-	1024	ReLU
BatchNorm	-	-	1024	-
Dropout	-	-	1024	-
Dense	-	-	3	Softmax

Tabla II: Arquitectura de la CNN (MiniNet-SP)

Tipo	Maps	Kernel/stride	Tamaño	Activación
Conv2D	16	3x3/1	222x222	ReLU
Conv2D	32	3x3/1	220x220	ReLU
AvgPool	-	2x2/2	110x110	-
Conv2D	64	3x3/1	108x108	ReLU
AvgPool	-	2x2/2	54x54	-
Conv2D	32	3x3/1	52x52	ReLU
AvgPool	-	2x2/2	26x26	-
Conv2D	32	3x3/1	24x24	ReLU
AvgPool	-	Global	32	-
Dense	-	-	32	Sigmoide
Dense	-	-	3	Softmax

aplicó regularización L2 con un factor de 0,02 para evitar el *overfitting*.

2) *Modelo basado en CNNs (MiniNet-SP)*.: En el contexto de las CNNs se ha introducido la práctica bastante habitual de introducir una capa de *pooling* luego de una capa convolucional, para generar una reducción prematura de las dimensiones del patrón de entrada. Para aprovechar esta práctica, se realizan experimentos con una arquitectura como la descrita en la Tabla II, denominada MiniNet-SP. Parece correcto afirmar que esta arquitectura permite una mayor extracción de atributos de interés, debido a que a medida que los filtros son más grandes cerca de la entrada extraen características generales, y luego cuando los filtros decaen jerárquicamente en tamaño permiten extraer características finas. La red contiene once capas; la primera y segunda son convolucionales, seguidas de una capa de *average-pooling* luego una dos veces capas de convolución seguidas de *average-pooling*, finalmente una capa de *flatten* seguida de una capa *fully-connected* densa. La salida de la capa *fully-connected* es alimentada a una función de activación *softmax*, que produce una distribución sobre las 3 etiquetas de las clases (ASP, SP, USP). La no linealidad ReLU es aplicada a la salida de cada capa convolucional.

IV. METODOLOGÍA

A. Conjunto de datos de entrenamiento

Los clasificadores descritos en este trabajo fueron entrenados con el mismo conjunto de datos usado en [5], los cuales fueron recolectados mediante capturas de una cámara RGB y validados por mediciones de *LOSA* para la precisa determinación del grado de liberación de hollín de la llama con respecto a su *smoke point*. El conjunto de datos se conforma de 488 imágenes con una resolución de 2592x1944 píxeles, las cuales antes de ser utilizadas fueron preprocesadas

normalizando el rango de entrada de los canales desde [0,255] a [-1,1], para luego re-escalarlas a un tamaño de 432x324 píxeles, finalmente tomando un recorte cuadrado de 224x224 centrado en la llama.

Realizar el entrenamiento de los algoritmos de clasificación con la baja cantidad de muestras disponibles puede conducir a *overfitting*. Debido a esto se aplican técnicas de aumento de datos al dataset original, en particular, el conjunto de datos original es amplificado aplicando corrimientos espaciales aleatorios a las ventanas de recorte de las imágenes tanto en el eje horizontal como vertical, simulando ligeros movimientos en la captura de la cámara. Las magnitudes del desplazamiento horizontal y vertical corresponden a distribuciones normales de media 0 y varianza $\sigma = 20$ y $\sigma = 7,5$ píxeles, respectivamente. Adicionalmente, se añade ruido gaussiano ($\sigma = 0,1$) a los tres canales de color de la imagen. Cada imagen del dataset original fue replicada 10 veces antes de realizar el aumento de datos, aplicando a cada copia los cambios ya descritos de forma aleatoria.

Para el experimento se realizan las mismas particiones de entrenamiento y validación sobre el conjunto de datos que en [5]. En primer lugar, se considera una partición compuesta de un 80 % de datos para entrenamiento y un 20 % de datos para validación. Se considera además otra partición utilizando para el entrenamiento aquellas imágenes con un índice de oxígeno de 50 % y 21 %, para luego realizar el proceso de validación con aquellas que imágenes con un índice de oxígeno de 35 % a fin de evaluar la capacidad del sistema de interpolar su habilidad de predicción. Se evalúan resultados considerando particiones con y sin aumento de datos.

B. Clasificación con SVM

Para ilustrar las diferencias de los sub-espacios generados por LDA y PCA a partir del mismo conjunto de datos (no aumentados), se aplican las transformaciones obtenidas por cada uno de los métodos, proyectando posteriormente los resultados a un espacio reducido. La Figura 2 muestra la proyección de las imágenes de llamas a un espacio de características en tres dimensiones que representa las tres componentes principales de mayor varianza para cada índice de oxígeno de la llama (21 %, 35 % y 50 %). Para cada caso se observa que las agrupaciones de datos generado relacionan los regímenes de combustión bajo *smoke point* (USP), en *smoke point* (SP) y sobre *smoke point* (ASP), con lo cual se evidencian patrones asociados al conjunto de imágenes que validan la utilización de un clasificador.

El modelo SVM definido clasifica los datos mediante la generación de un hiperplano. En un espacio tridimensional, el hiperplano es un sub-espacio de dos dimensiones. El proceso de entrenamiento del modelo se realiza a través de optimizar los parámetros para minimizar la diferencia entre la salida esperada y la salida calculada por el modelo con el fin de aprender el comportamiento de los datos y poder inferir nuevos comportamientos, y posteriormente generalizar sobre nuevos conjuntos de datos. Dentro del contexto de las SVM, algunas investigaciones han arrojado la propuesta de diferentes kernels, los cuatro kernels básicos son: lineal, polinomial, sigmoid y función de base radial (RBF). En este caso la elección es RBF.




Fig. 1: Ejemplos de imágenes de entrada a los algoritmos de clasificación. La columna izquierda son fotos sin modificar, y las de la columna derecha pasaron por una etapa de aumento de datos.

C. Procedimiento de entrenamiento CNNs

En el contexto de *transfer learning*, se utilizarán los modelos Oxford VGGnet (pre entrenado con ImageNet sin sintonización fina) y MobileNet. Además, con los datos provistos luego del aumento de datos, se realiza la adaptación de un modelo entrenado desde cero (MiniNet-SP). En el proceso de entrenamiento se empleó el optimizador Adam con *batches* de tamaño 32, y una tasa de aprendizaje inicial de 7×10^{-4} para el caso de MobileNet y MiniNet-SP, el cual se multiplicaba por 0,5 cada 10 épocas de entrenamiento (momento en que también se medía la precisión en el conjunto de validación), hasta un máximo de 100 épocas. Para evitar el *overfitting*, el entrenamiento era detenido al detectar una disminución en la precisión en el conjunto de validación (dos disminuciones seguidas en el caso de MobileNet). VGG16 fue entrenada con una tasa de aprendizaje de 10^{-3} por 30 épocas, obteniendo resultados satisfactorios sin necesidad de modificaciones adicionales a la tasa de aprendizaje.

Tabla III: Precisión de clasificación en el conjunto de validación para el *set de datos* particionado con un 20 % de datos para validación (80/20), y partición alternativa con llamas de OI = 35 % para validar, usando el resto para entrenar (21/50, 35). Se muestran los resultados sin y con *aumento de datos* para cada *set de datos* (Aug).

Model	Accuracy			
	[80/20]	[80/20]-Aug	[21/50,35]	[21/50,35]-Aug
LDA + SVM	0.959	0.420	0.226	-
PCA + SVM	1	0.617	0.380	-
VGG16	1	1	0.425	0.386
MobileNet	0.821	1	0.456	0.396
MiniNet-SP	0.789	1	0.381	0.422

V. RESULTADOS EXPERIMENTALES

la transformación no es perfecta para tareas de clasificación con SVM, lo cual indica que incluir modelos basados en redes neuronales convolucionales es una solución coherente donde los datos de entrenamiento, al ser aumentado artificialmente, aumentan la robustez del modelo, ya que incluyen parte de estos problemas pero no generan confusión en las etiquetas, esto se justifica ya que las CNNs tienen la propiedad de invarianza y explotan la capacidad de extraer características basadas en su banco de filtros.

En esta sección se presentan los resultados de los experimentos ejecutados sobre los conjuntos de datos descritos en la sección A. Además, se compara el desempeño del clasificador entrenado mediante SVM con las arquitecturas de CNNs. Finalmente, se realiza la caracterización de los tiempo de inferencia promedio a fin de evaluar su uso en aplicaciones de tiempo real.

A. Clasificador SVM versus Arquitecturas CNN

La determinación del régimen de combustión basados en el SPH con SVM incluye como primera instancia la reducción de la dimensionalidad para representar la imagen original en un espacio reducido de características. En la práctica, la estimación de esta representación requiere tener una muestra completamente representativa del espacio de entrada que permita una correcta proyección sobre imágenes no contempladas durante el proceso de entrenamiento.

En la práctica, variaciones entre las imágenes de llama no son solo consecuencia de las distintas alturas y morfología en la punta de la llama, sino que también son causadas por factores externos como la luminosidad, fondo, corrimientos, entre otros, los que pueden variar dependiendo de las condiciones de adquisición de la imagen. Como resultado, la transformación debida a la reducción de la dimensionalidad del conjunto hace que la similitud entre dos imágenes no se deba necesariamente a que su proceso de adquisición fue bajo las mismas condiciones o que estén asociadas a la misma etiqueta. Lo anterior ocasiona un mal desempeño de reconocimiento como se muestra en la Tabla III, por lo tanto,

B. Evaluación de desempeño

La implementación de los experimentos se realiza empleando Python 3.6, en una computadora con 32 GB de




Fig. 2: Representación de imágenes de llama en un espacio de características 3D para índices de oxígeno (OI) y condiciones de SPH

Tabla IV: Tiempos de inferencia para cada uno de los modelos propuestos.

Model	FPS
LDA+SVM	4027.7
PCA+SVM	541.2
VGG16	124.4
MobileNet	134
MiniNet-SP	311

RAM y una CPU Intel Core i5-8600K, equipada con una GPU NVIDIA Titan RTX bajo el sistema operativo Ubuntu 16.04. Considerando un conjunto de entrenamiento de 5,000 imágenes se tarda aproximadamente dos minutos en entrenar la SVM y diez minutos para entrenar los modelos basados en CNNs. Se realizaron múltiples mediciones de la velocidad de inferencia de los modelos utilizando un *batch* de 976 imágenes, reportando en la Tabla IV el promedio sobre 50 mediciones distintas. Además, en la figura 3 se muestra la relación entre la velocidad de inferencia y la precisión en la clasificación de los algoritmos.

VI. CONCLUSIONES

Se presenta un nuevo método para la detección del estado de propensión a la liberación hollín de una llama basado en la utilización de CNNs y su *smoke point* definiendo tres posibles clases (USP, SP, ASP). Con respecto a la efectividad para la detección de los regímenes de *smoke point* se realiza una comparación con estudios anteriores basados en SVM como punto de comparación. Los resultados obtenidos son satisfactorios; el mayor problema identificado en los enfoques




Fig. 3: Precisión de clasificación de los algoritmos vs velocidad de inferencia (FPS)

previos basados en un clasificador por SVM corresponden a los corrimientos espaciales y ruido en la adquisición de los datos, los cuales disminuyen el desempeño del clasificador debido a que imágenes de llama en estas condiciones quedan mapeadas a *clusters* con mayor dispersión, lo que dificulta su separabilidad. El problema es subsanado en gran medida por el uso de CNNs, las cuales son capaces de adaptarse de

mejor manera a este tipo de perturbaciones. Adicionalmente, se realiza la caracterización de los tiempos de inferencia para cada uno de los modelos expuestos, obteniendo cifras prometedoras para una futura implementación de un sistema de clasificación en tiempo real. Dicho sistema eventualmente podría servir de base para la implementación de un lazo de control de un proceso de combustión a nivel industrial a fin de mantener la llama en un estado óptimo de eficiencia energética en su combustión. Lo anterior depende de la obtención de un *dataset* con un mayor número de clases, a fin de aumentar la granularidad de las predicciones y aumentar la certeza sobre el estado actual de la llama con respecto a su *smoke point*, de esta forma, de obtener un *dataset* etiquetado que muestre suficientes ejemplos de una variación continua del estado de emisión de hollín de la llama, se podría entrenar un sistema de regresión que permita la implementación de un controlador con la precisión necesaria.

REFERENCIAS

- [1] C. S. McEnally and L. D. Pfefferle, "Sooting tendencies of nonvolatile aromatic hydrocarbons," in *Proceedings of the Combustion Institute*, vol. 32, pp. 673 – 679, 2009.
- [2] "ASTM D1322-18, Standard Test Method for Smoke Point of Kerosene and Aviation Turbine Fuel," standard, ASTM International, West Conshohocken, PA, 2018.
- [3] R. J. Santoro, H. G. Semerjian, and R. A. Dobbins, "Soot particle measurements in diffusion flames," *Combustion and Flame*, vol. 51, pp. 203 – 218, 1983.
- [4] G. Rubio-Gomez, L. Corral-Gomez, J. A. Soriano, A. Gomez, and F. J. Castillo-Garcia, "Vision based algorithm for automated determination of smoke point of diesel blends," *Fuel*, vol. 235, pp. 595–602, 2019.
- [5] J. Pino, H. O. Garcés, J. Cuevas, L. E. Arias, A. J. Rojas, and A. Fuentes, "Soot propensity by image magnification and artificial intelligence," *Fuel*, vol. 225, pp. 256–265, 2018.
- [6] P. N. Belhumeur, J. P. Hespanha, and D. J. Kriegman, "Eigenfaces vs. fisherfaces: Recognition using class specific linear projection," *IEEE Transactions on Pattern Analysis & Machine Intelligence*, no. 7, pp. 711–720, 1997.
- [7] O. Chapelle, P. Haffner, and V. N. Vapnik, "Support vector machines for histogram-based image classification," *IEEE transactions on Neural Networks*, vol. 10, no. 5, pp. 1055–1064, 1999.
- [8] J. Gu, Z. Wang, J. Kuen, L. Ma, A. Shahroudy, B. Shuai, T. Liu, X. Wang, G. Wang, J. Cai, *et al.*, "Recent advances in convolutional neural networks," *Pattern Recognition*, vol. 77, pp. 354–377, 2018.
- [9] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, *et al.*, "Imagenet large scale visual recognition challenge," *International journal of computer vision*, vol. 115, no. 3, pp. 211–252, 2015.
- [10] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, "Mobilenets: Efficient convolutional neural networks for mobile vision applications," *arXiv preprint arXiv:1704.04861*, 2017.
- [11] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv preprint arXiv:1409.1556*, 2014.