



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Laboratorio Análisis de textos y Calificaciones

EIN092B - Visualización

Jorge Portilla

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

Introducción al procesamiento del lenguaje natural

- Encontrar patrones en un texto, solía ser complejo.
- Técnicas especializadas que permiten que los algoritmos interpreten o generen texto para resolver tareas específicas, como traducción automática, análisis de sentimientos, clasificación de texto, entre otras aplicaciones.
- Aplicaciones comunes incluyen asistentes virtuales (Siri, Alexa), traducción automática (Google translate), *chatbots*, análisis de sentimientos, entre otras.

- **Tokenización** es el proceso de dividir un texto en unidades más pequeñas llamadas **tokens**.
- Los **tokens** pueden ser: palabras individuales, frases y oraciones.
- Permite procesar el texto para análisis posteriores y suele ser el primer paso para la mayoría de algoritmos de procesamiento de lenguaje natural.

Ejemplo:

- **Texto:** “¿Para qué hacer esto?.”
- **Tokens:** ['¿', 'Para', 'qué', 'hacer', 'esto', '?']

Stopwords

- Las **stop words** son palabras comunes que no aportan mucho significado en el análisis.
- Ejemplos: *el, la, de, en, y, por, que, etc.*
- Nos enfocamos en las palabras clave que son más relevantes.

Ejemplo:

- **Texto:** “¿Para qué hacer esto?”
- **Tokens:** ['¿', 'Para', 'qué', 'hacer', 'esto', '?']
- **Stop Words eliminadas:** ['hacer', 'esto']

Lemmatizer

- El `lemmatizer` de NLTK (Natural Language Toolkit) es una herramienta que reduce las palabras a su forma base o "lema". Un lema es la forma base de una palabra, como un verbo en infinitivo o un sustantivo en singular.
- El `lemmatizer` tiene en cuenta el contexto gramatical y devuelve una palabra válida en el idioma.
- Usa la base de datos de *WordNet* para encontrar la forma base de la palabra, mapeando las formas flexionadas a sus respectivos lemas según su rol gramatical.

Lemmatizer

- El `lemmatizer` de NLTK (Natural Language Toolkit) es una herramienta que reduce las palabras a su forma base o "lema". Un lema es la forma base de una palabra, como un verbo en infinitivo o un sustantivo en singular.
- El `lemmatizer` tiene en cuenta el contexto gramatical y devuelve una palabra válida en el idioma.
- Usa la base de datos de *WordNet* para encontrar la forma base de la palabra, mapeando las formas flexionadas a sus respectivos lemas según su rol gramatical.

Ejemplo:

- **Texto:** "Los estudiantes están haciendo el laboratorio antes de ir a clase."
- **Lemmatizer:** `['El', 'estudiante', 'estar', 'hacer', 'el', 'laboratorio', 'antes', 'de', 'ir', 'a', 'clase']`

Stemming

- Stemming simplemente corta los sufijos de las palabras para obtener una raíz.
- Utiliza un diccionario y el contexto gramatical de la palabra (como el tiempo verbal, número o género) para reducirla a su forma base. En lugar de simplemente cortar sufijos, WordNet Lemmatizer consulta un corpus (como WordNet) para encontrar la forma canónica (lema) de una palabra.


Ejemplo:

- **Texto:** “Los estudiantes están haciendo el laboratorio antes de ir a clase.”
- **Tokens:** ['Los', 'estudiantes', 'están', 'haciendo', 'el', 'laboratorio', 'antes', 'de', 'ir', 'a', 'clase']
- **Stemming:** ['Los', 'estudiant', 'estan', 'hac', 'el', 'laborator', 'ant', 'de', 'ir', 'a', 'clas']

Embeddings y representaciones vectoriales

- Las palabras se representan como vectores en un espacio de características de dimensión m .
- Cada palabra deja de ser un símbolo único, y se convierte en un conjunto de valores numéricos..
- Los embeddings son representaciones densas y de baja dimensión de palabras o elementos.
- Capturan información semántica: palabras con significados similares estarán más cerca entre sí en el espacio vectorial.
- Aprendidos automáticamente durante el entrenamiento de modelos de aprendizaje profundo, como en Word2Vec o GloVe¹.

¹word2vec is described in Mikolov, Chen, Corrado, and Dean (2013), available at <https://code.google.com/archive/p/word2vec>. GloVe is described in Pennington, Socher, and Manning (2014), available at <https://nlp.stanford.edu/projects/glove>.



Representación de una secuencia de 20 palabras que representan un solo documento: codificación one-hot usando un diccionario de 16 palabras (panel superior) e incrustado en un espacio m -dimensional con $m = 5$ (panel inferior).

Respecto al panel inferior, los vectores no son binarios, sino que tienen valores continuos y se obtienen generalmente mediante técnicas de aprendizaje, como Word2Vec o GloVe.

- Una secuencia de n elementos consecutivos de un texto o discurso.
- Los elementos pueden ser palabras, caracteres o cualquier otro tipo de unidad.
- Se utilizan para modelar la probabilidad de la ocurrencia de una palabra basada en las anteriores.

Ejemplo:

- **Texto:** "Los estudiantes están realizando experimentos en el laboratorio."
- **Bigramas ($n = 2$):**
['Los estudiantes', 'estudiantes están', 'están realizando', 'realizando experimentos', 'experimentos en', 'en el', 'el laboratorio']